


AI 最底层的 Raw Model

从 Token 输入、概率分布，到上下文、权重、训练与多模态。按讲解顺序保留提问、例子和推导，结合原始板书阅读。

学习路径

- 01 剥离上层功能，先看 Raw Model
 - 02 自然语言如何变成 Token 列表
 - 03 输出是下一个 Token 的概率分布
 - 04 上下文窗口：长度与容量估算
 - 05 装得下，不代表处理得好
 - 06 权重矩阵、下载体积与参数量
 - 07 训练、微调，以及语料为什么重要
 - 08 通过模型架构调用权重
 - 09 输入、权重与算法共同产生输出
 - 10 数学函数、GPU 与浮点数误差
 - 11 多模态：数字输入与输出解释
 - 12 回到整体结构，衔接模型服务
-

01 · 剥离上层功能，先看 Raw Model



原课画面 · 点击放大

它知不知道什么叫自然语言？它知不知道你说的话是什么意思？它知不知道什么叫中文、什么叫英文？它知不知道？你看它的输入输出就完事了。它输入的是个啥？这是中文吗？这是英文吗？这是图片吗？这是视频吗？这是啥？

好，各位同学，咱们今天聊的是 Raw Model，我把它翻译成为“裸模型”。裸模型是整个 AI 技术体系的最底层，就是无论你用什么样的 AI 技术，最终你都是用的它——裸模型。

其实有些资料里边用的是另外一个词，叫“基础模型”，或者把 Raw Model 翻译成“原始模型”。其实无所谓。我把它翻译成“裸模型”，就是告诉同学们：这一块剥离了任何花里胡哨的功能，看到 AI 最本质的真相，就是这个东西。


而且这一块的技术，在原理上或者知识体系上是非常稳定的。从那个 2023 年 GPT-3.5 出来到现在，它就没变过，一直是这么一套技术体系。

这个模型到底是啥呢？简单理解，它就是一个函数：接收一个输入，产生一个输出。输入是啥？输入我们把它叫做 Token 列表。什么叫 Token 列表？你可以把它想象成一个数字的数组。

画面与校读说明

白板中心是 Raw Model 方框，左侧箭头指向模型，右侧箭头从模型引出，建立输入与输出的函数示意。

02 · 自然语言如何变成 Token 列表



原课画面 · 点击放大

比方说，数字就是这么一个东西：2、3、4、5、1、8。数字有可能很大。那这个 Token 到底是什么东西？它就是我们的自然语言换算成数字的结果。至于怎么换算，你暂时不用管，这个东西叫做分词。

一般来说，我们中文平均一个字能分出 1.5 个 Token。注意，是平均下来。你说哪有半个 Token？其实没有。有的中文可能就是一个 Token，有的可能两个 Token，甚至三个 Token。平均下来，中文就是 1.5 个 Token。也就是一个字约等于 1.5 个 Token。


那么英文呢？英文一个单词，大概分出来是 1.3 个 Token，大概这样。但每个单词分出来可能不一样，比如有词根，还有前缀，都可能进行划分。

最终，我们给裸模型一个消息，这个消息会先进行分词，把它分成一个个 Token，就会形成一串数字。

画面与校读说明

便笺列出数字数组 [2,3,4,5,1,8]，并写有“中文：1个字≈1.5 token”“英文：1个单词≈1.3 token”。左侧输入标为 Token List。比例是本课使用的近似估算口径。

03 · 输出是下一个 Token 的概率分布



原课画面 · 点击放大

把这串数字喂给或者说传递给裸模型，它得到的是什么？得到的是一个概率分布。什么概率分布？就是下一个 Token 的概率分布。

得到的大概是这么一个数据结构，用一个对象表示：你给了它一串数字，它得到的是下一个数字有哪些可能性。比如说 15，可能性为 0.7，也就是 70%；下一个 Token 是 288 的可能性为 0.2。它把各种可能性排列起来，这就是裸模型，没了。


裸模型就是做一套数学计算，就在做这么一个事：算出下一个 Token 的概率分布。这跟我们平时用的模型，或者一些 AI 工具，感觉差别特别特别大，对吧？因为这是最底层的東西。上层怎么利用它玩出那些花样，我们后边再说。最核心的东西没了，裸模型就这样子。

你说这个玩意儿有什么意义？你想，这些数字跟我们的自然语言有对应关系。比如中文，一个数字可能对应半个或者一个中文。这些数字串起来，会串成自然语言，对不对？它返回的下一个 Token，是不是也是自然语言的一部分？比如这一串得到的自然语言可能是“你好”，下一个数字可能表示一个逗号，也有可能表示“吗”，是不是这个意思？

画面与校读说明

模型输出箭头标为“概率分布”。便笺展示 15:0.7、288:0.2 等候选项，旁边出现“你好”的续写示例；这些是教学示意，并非某个实际模型的实测概率。

04 · 上下文窗口：长度与容量估算



原课画面 · 点击放大

那就是往后边猜测下一个词到底是啥，或者下一个字到底是啥。这个图同学们一定要记住，这就是裸模型最原始的状态。

后边还有很多平时蛮常见的术语，我给大家解释一下：这些术语在这个图里面对应哪个地方。第一个就是“上下文窗口”，叫 Context Window。这是什么？非常简单，你只要知道这个图，就很好解释：它指的就是这个 Token 列表的长度，就这么简单。

比方说，这个数组的长度为 100，那么目前的上下文窗口就是 100。平时我们说，新发布的一个模型支持最大的上下文窗口多少多少，是什么意思？就是它最大能支持多长的输入长度。超过这个长度它就受不了了，它也不会给你报错，就把前面的东西截断。比如只支持一万的上下文窗口，结果你传了两万，前面的一万它就不要了，自动扔掉。这就是最大的上下文窗口。

目前一般的上下文窗口，128K 是比较常见的。这个 K 不是说占了什么磁盘空间，跟磁盘空间没有关系；K 表示千。算出来是 12.8 万，就是这个数组的长度最大可以是 12.8 万。

你可以想一想，12.8 万换成中文，可以容纳多少个字？平均一个文字占 1.5 个 Token，我们就估算一下：128,000 除以 1.5，大概就是八万多个中文字符。除了 128K，还有 256K，还有 1M，一兆。注意，这不是磁盘空间；一兆指的是一百万，million。


如果是 1M，支持多少中文字符？除以 1.5，就支持大概六十六万个中文字符。也就是说，这个函数能处理的最大的 Token 数量，就是上下文窗口，好理解了吧？

不过有一个特性要给同学们说一下：上下文窗口指的是它能装得下的 Token 数量，最大能够处理多少个 Token，并不代表它能够把这些东西处理好。现在 AI 也是有泡沫的，同学们都知道，大模型之间的竞争也比较激烈。

画面与校读说明

便笺依次列出“上下文窗口 / Context Window”、128K（12.8万 token）、256K 和 1M。讲解中的自动截断是原课描述，不能直接作为所有服务接口的行为保证；字符换算沿用本课的估算假设。

05 · 装得下，不代表处理得好



原课画面 · 点击放大

各大厂商为了让自己的模型有卖相，不停地给你堆参数，可能结果你用下来不是那么回事。什么意思？比如它支持 1M 的上下文窗口，指的是 Token 列表长度能够容纳一百万。但是你把这些东西扎扎实实扔进去之后，会发现好多东西根本处理不过来。

同学们平时用 AI，有没有发现一个现象？刚开始打开一个新的窗口，跟它聊天，觉得它挺聪明，你说啥它都记得住。当你聊了很多之后，会发现它变傻了，之前一些规则忘了。明明说好每次写完代码要提交，它把这个规则忘了；明明说好一个代码文件、一个模块不能超过 200 行代码，它写的时候就忘了。

为什么？这就是上下文窗口的问题。虽然它能够容纳这么多 Token，但是它记不住。弄了很多之后，模型能力会下降。这提示我们，模型原生有这么一个特性，所以平时用模型，那些相对独立的事情，尽量新开上下文窗口去做。


后面我们还会讲一些工具的使用，你会发现它会用很多子代理。为什么要用子代理？就是来处理这个问题。这是第一个概念，叫上下文窗口。

第二个，我们到模型这一部分来。目前把它看成一个函数。实际上它是不是函数？实际上它不是函数，它是什么？它是一个矩阵。应该说，这个函数是我们自己写的。

画面与校读说明

板书仍保持 Token List → Raw Model → 概率分布，以及上下文容量便笺；讲解由容量转向使用表现，再指回模型方框，为权重矩阵概念作过渡。

06 · 权重矩阵、下载体积与参数量



原课画面 · 点击放大

实际上这个函数里面在调用一个矩阵。这里我用一个双向箭头，把它叫做“权重矩阵”。我跟你们说一下到底怎么回事：实际上我们的模型是这个东西。

有些同学可能在本地部署过模型。本地部署的时候，是不是要把模型下载到本地？下载的实际上是啥？就是这个矩阵。当然还有一些其他的配置文件，比如 config 之类，不过核心就是这个矩阵。

矩阵是啥？就是一串数字，超级多的数字。下载模型时你会发现，有些模型几个 G、几十个 G、几百个 G，甚至一个 T。主要占空间的，就是这个矩阵，数字超级多。

我们平时经常说，这个模型有多少参数，那个模型有多少参数，指的是什么？就是矩阵里面数字的数量。比方说一个模型有 7B，B 是什么？billion，十亿。7B 就是七十亿个参数。换句话说，矩阵里面有七十亿个数字，简单吧？


一般本地模型是 7B、16B，不会太大。但是一些商用级的，放到专用推理服务器上，那些模型的参数就比较大。目前有超过一个 T 的——不是一个 T，是十个 T。我记得什么 GPT-5 还是什么模型，是超过十个 T 的，十万亿以上的参数。T 就是万亿，指矩阵里面有十万亿个数字。

我们平时说的模型训练，指的是什么？就是得到这样一个矩阵的过程。训练的目的是什么？生成一个权重矩阵。至于它怎么训练，如何得到这个矩阵、里面是什么意思，是大模型工程师，也就是算法工程师要考虑的事情。跟咱们没关系，你只需要知道这个概念。

画面与校读说明

Raw Model 与下方“权重矩阵”用双向箭头相连。便笺显示“模型参数”“7B”“70亿个参数”。“GPT-5还是其他模型超过10T”在原讲解中带有记忆不确定性，此处仅保留原话，不把该模型名称及规模当作已核事实实。

07 · 训练、微调，以及语料为什么重要



原课画面 · 点击放大

有的时候说要对模型进行微调，也是指处理这个矩阵。训练是什么？从无到有，一开始没有这个矩阵，通过训练得到一个矩阵的过程。

微调是什么？已经有这个矩阵了，通过一些二次训练，对矩阵里面有些数字做一些改动，能理解吧？我们站在外面看，不深入到里面。里面是一个黑盒子，你不用去管它怎么得到。


无论训练还是微调，原材料都是语料。因为模型的本质作用是：给我一个 Token 列表，我来预测下一个 Token 的概率分布，对吧？它一定要见过足够多的 Token，预测的结果才更加精准，或者更加合理。所以它要进行语料的训练。

为什么现在编程模型那么强大？主要是因为我们有大量庞大的开源库，里面有大量各种编程语言的代码，可以通过这些语料训练。见过足够多的 Token 之后，它能够进行下一个 Token 的预测。

画面与校读说明

指向权重矩阵的左侧箭头标有“训练/微调”，下面标有“语料”，直观区分训练材料、形成的权重与运行时的 Token 输入。

08 · 通过模型架构调用权重



原课画面 · 点击放大

训练的结果就是这个权重矩阵。严格来说，裸模型是啥？裸模型是一个矩阵，它不是一个函数。但是模型要用，你不能光把这些数字给我，我怎么用？因此一般会通过 Hugging Face 的一个库去调用模型。

调用方式要看你用什么样的模型架构。目前最常见的是什么架构？来，大声告诉我，就是 Transformer 模型架构。你可以用 Transformer 这个架构，它里面可以提供一个函数去调用这个矩阵。


如果用另外一些架构，比如 Tensor，那就用 Tensor 里面提供的函数去调用矩阵，懂那个意思吧？不同架构使用矩阵的方式不一样。一般来说，训练的时候基于什么架构来训练，就要用什么架构来调用。

比如现在用的大模型都是基于 Transformer 架构训练的，训练出来的权重矩阵，肯定要用 Transformer 架构调用。用别的架构能不能调用？如果要调用，就要对矩阵做一些转换，就是这套模式。

画面与校读说明

便笺上写有“Transformer架构”和“Tensor架构”。这里忠实保留原课的术语及说法；Tensor 的具体所指没有展开，不把它补写成经核实的另一种模型架构。

09 · 输入、权重与算法共同产生输出



原课画面 · 点击放大

顺便多说一句，这套模式属于神经网络和深度学习，它们使用这种方式。如果用机器学习之类其他的 AI 技术，可能就不是这套模式了。我们现在讲的是基于神经网络和深度学习的模式。不扯远了，因为目前基本上玩的都是 Transformer。

这一块再总结一下：你传入一个 Token 列表，传给这个函数。这个函数是基于 Transformer 架构的函数，拿到 Token 列表之后要进行一段运算。运算过程就是使用矩阵里面的参数，也就是各种各样的数字，再结合输入，加上算法，得到概率分布的结果。

所以大模型的本质是啥？从技术上讲，是一个数学函数，甚至可以认为它是个纯函数——不是可以认为，它就是个纯函数。Token 列表一定，得到的结果就不变化。

画面与校读说明

图中以红框标出 Token List、Raw Model 和权重矩阵，展示输入、计算过程与参数的关系。此处“纯函数”是原课采用的数学抽象，下一段继续补充实际计算误差。

10 · 数学函数、GPU 与浮点数误差



原课画面 · 点击放大

你输入 1、2、3，它就得到 4。我随便举几个例子，输入不变，得到的结果就不变。再说得吓人一点，它跟这个东西没有什么区别：纯函数，输入 1 加 2 等于 3。只不过公式没有这么简单，是一个比加法更复杂的公式，得到一个结果。

所以你看网上有些人都开始崇拜 AI 了，快形成宗教了。什么“AI 要统治全人类”“AI 开始出现自我意识”“AI 开始对人类发脾气”，你看一下这个东西就行了。他天天膜拜的是啥？膜拜的是一个函数，就是我们高中课本里面一个公式。他说那个玩意开始出现感情了，我也不知道这个东西能有啥感情。它就是数学运算，传入什么得到什么，而且是纯函数，不会变化。

当然，理论上是纯函数，实际上可能没有那么纯。原因不是函数不是纯函数，函数还是纯函数，只是在运行的时候经过 GPU。因为参数量太大，要计算的数学运算太多，因此需要通过 GPU 并行运算。它把数学公式进行拆解，拆解后运算，最后合并，大概这个意思。

由于 GPU 是并行运算，就会导致一个问题。计算机世界里使用浮点数，没问题吧？浮点数不满足结合律。什么意思？我给你们举个例子，放大一点： $0.1 + 0.2 + 0.3$ ，它有误差，对不对？再看另外一个，很神奇， $0.1 + (0.2 + 0.3)$ ，就没有这个显示出来的误差了。

你看，它不满足结合律。在计算机浮点数的世界里，前面这个等于后面这个吗？你会发现它不等于。至于为什么，以前我有一个抖音短视频专门讲过，讲这种误差到底怎么来的。万万没想到在这里用上了。所以知识永远是有用的，你不知道将来会在哪里用上。


总之它不满足结合律。有什么问题？现在有一个很长的公式需要运算，一拆解，拆解位置不同，得到的结果就可能不一样。所以理论上是纯函数，实际上可能没有那么纯。

好，老有同学说：“袁老师，现在的模型不都是什么多模态模型吗？怎么解释多模态？”我告诉你，没有什么好解释的，一样的。

画面与校读说明

浏览器控制台完整显示： $0.1+0.2+0.3 \rightarrow 0.6000000000000001$ ； $0.1+(0.2+0.3) \rightarrow 0.6$ ；两式比较得到 false。这是浮点加法顺序的演示。“感情、自我意识”等评论属于原讲者观点，不能把函数示意视为对该议题的完整证明。

11 · 多模态：数字输入与输出解释



原课画面 · 点击放大

对这个东西来说，我问你，听到现在，它知不知道什么叫自然语言？它知不知道什么叫中文、什么叫英文？你好好想一想。

我再问一次：它知不知道什么叫自然语言？知不知道你说的话是什么意思？知不知道什么叫中文、什么叫英文？它知不知道？你看输入输出就完事了。它输入的是啥？这是中文吗？英文吗？图片吗？视频吗？这是啥？这是一个数字的数组，它哪知道这个数字是什么东西？它不知道。因为它对它来说都是数字，它不知道那是什么。反正看到这个数字，经常后面会跟另外一个数字，它不知道那是什么意思。

这是很多人崇拜的、要产生自我意识的模型，就是这么个东西。因此什么多模态，什么图片、视频、音频、声音，对它来说没有区别，都是数字。经常训练，看到这个数字后面跟另外一个数字，就可以算出概率分布，就是这个意思。

当然里面没有那么简单，还有一些特别的东西，那是模型内部的东西，我们不扯远。总之基本上就是这个逻辑。音频也好、视频也好、图像也好，对它来说都是数字。你给它训练什么，它就能做什么。


只不过人拿到这个东西之后，要分辨一下。比如我这句话是“请帮我生成一张什么什么图片”，它吐出来一个 Token——不是一个 Token，是下一个 Token 的概率分布。那么我要判断，这个 Token 是文字还是图像。

其实也很好判断，因为 Token 是一个字典，有字典列表。比如它给我一个 500008，随便举的。我发现这个 Token 落在一个叫 image 范围的区间，原来知道它是跟图像相关的东西。那么就把它当成图像里面的信息，再进行转码、转换，得到一个图像可能某个像素点的信息，懂这个意思吧？好，就没啥了，裸模型认识到这里就够了。

画面与校读说明

板书保留 Token List、Raw Model、GPU、权重矩阵及概率分布。便笺标注“多模态 没有区别”，并写出 500008 指向 image_file 的例子。该编号和像素解释是原课的简化示意，不是具体多模态系统的通用编码规范。

12 · 回到整体结构，衔接模型服务



原课画面 · 点击放大

这套东西，从 Transformer 出现那一天起到现在，应该有八年多了吧，七八年了，就没变过。

我们现在玩什么？无非是这么几个地方：怎么训练一套矩阵出来；给的语料可能有中文、英文、代码、图像，让它能够适配多种 Token 的预测。但是这个函数没变，都是这个样子，无非是调用矩阵得到下一个概率分布。不同模型就是不同矩阵，它们能支持的最大上下文不一样，仅此而已。

还记得以前我一个视频里面说的吗？我说 Transformer 发展到现在没有本质的变化，为什么这样说？就是指这个，它的基础能力没有什么本质的变化。现在从技术角度跟你讲清楚这个原因。

理解到这一层之后，就可以很好地理解接下来要讲的上一层——模型服务那一层，它又是怎么基于这个东西玩出花样的。好，咱们下节课再说。

画面与校读说明

最终结构图包含 Token List → Raw Model → 概率分布；Raw Model 经 GPU 与权重矩阵连接；语料通过训练/微调形成或调整权重。最后回到这一整体图，预告下一层的模型服务。

来源：用户提供的《2.AI最底层的Raw Model.mp4》。正文保留原讲者的顺序与口吻，仅整理标点、明显识别错误和分块衔接；画面与校读说明单独列出。课程中的历史表述、估算、观点及不确定说法按原讲解保留，未作外部事实核验。

处理记录：本地 Qwen3-ASR 0.6B INT8 转写；37 个原始音频块，12 个图文段落、12 张关键画面。音频块时间约为25秒粒度，不是逐词对齐；原始转写保存在 source-materials。实际模型 Token 用量与费用未由运行环境提供。